

基于VMD-LSTM-LightGBM的多特征短期电力负荷预测

张未^{1,2}, 余成波^{1,2}, 王士彬³, 李涛⁴, 何鑫^{1,2}, 陈佳^{1,2}

(1. 重庆理工大学电气与电子工程学院, 重庆 400045; 2. 重庆市能源互联网工程技术研究中心, 重庆 400045; 3. 国网重庆市电力公司市南供电分公司, 重庆 401336; 4. 国网四川省电力公司遂宁供电公司, 四川 遂宁 629000)

摘要: 针对目前多特征电力负荷预测精度不准的问题, 为充分挖掘电力负荷数据中的时序信息、天气信息等特征信息, 提出了一种基于变分模态分解(variational mode decomposition, VMD)的长短期记忆(long short-term memory, LSTM)神经网络与轻量级梯度提升机(light gradient boosting machine, LightGBM)预测模型, 优化负荷数据非线性、非平稳、长记忆等问题, 解决了多特征预测提取特征信息差的问题。该方法首先用VMD分解代表不同尺度的特征模态分量, 降低了原始序列的不平稳度, 同时分解的残差量代表负荷数据强非线性部分, 通过特征性强的算法进行预测, 将各模态分量通过LSTM的单特征预测, 再将各个分量加入多特征利用LightGBM进行负荷预测。通过与目前多特征电力负荷预测模型进行对比实验, 平均绝对误差(mean absolute error, MAE)值仅为其23%~73%, 平均绝对百分比误差(mean absolute percentage error, MAPE)值能达到0.37%, 具有更好的预测精度。

关键词: 多特征; 变分模态分解(VMD); 长短期记忆(LSTM); 轻量级梯度提升机(LightGBM); 短期负荷预测; 残差量

Multi-Featured Short-Term Power Load Forecasting Based on VMD-LSTM-LightGBM

ZHANG Wei^{1,2}, YU Chengbo^{1,2}, WANG Shibin³, LI Tao⁴, HE Xin^{1,2}, CHEN Jia^{1,2}

(1. College of Electrical and Electronic Engineering, Chongqing University of Technology, Chongqing 400045, China; 2. Chongqing Energy Internet Engineering Technology Research Center, Chongqing 400045, China; 3. State Grid Chongqing Shinan Electric Power Supply Branch, Chongqing 401336, China; 4. State Grid Suining Electric Power Supply Company, Suining, Sichuan 629000, China)

Abstract: Arming at the current inaccurate problem of multi-feature power load prediction accuracy, in order to fully exploit the feature information such as time-series information and weather information in power load data, a variational mode decomposition (VMD)-long short-term memory (LSTM) neural network-light gradient boosting machine (LightGBM) based prediction model is proposed to optimize the problems of non-linearity, non-stationary and long memory of load data, and solve the problem of poor extraction of feature information for multi-feature prediction. The method first decomposes the characteristic mode components representing different scales with VMD, which reduces instability of the original sequence, while the residual amount of the decomposition represents the strongly nonlinear part of the load data, which is predicted by the characteristic strong algorithm. Each modal component is predicted by the single feature of LSTM, and then each component is added to the multi-feature using LightGBM for load prediction. Experimental comparison with current multi-characteristic power load forecasting models through example analysis is conducted, the proposed method MAE value is only 23% ~ 73%, and MAPE value can reach 0.37%, with better prediction accuracy.

Key words: multi-features; variational mode decomposition (VMD); long short-term memory (LSTM); light gradient boosting machine (LightGBM); short-term load forecast; residual amount

基金项目: 国家自然科学基金资助项目(61976030)。

Foundation item: Supported by the National Natural Science Foundation of China (61976030).

0 引言

随着社会经济的快速发展,由于化石能源逐渐枯竭,传统的火力发电存在效率低下、环境污染严重等问题,我国在2020年9月提出双碳政策^[1]。整个电力系统需要维持电力电量平衡,降低电网运行过载风险,提高电力设备的利用率、降低能耗,针对多特征的电力负荷预测的研究至关重要^[2-4]。双碳政策促进了电网发电侧与用户侧用能需求的多元化发展,以及近些年大数据和通信技术的应用,通过多种特征进行负荷预测成为研究重点。

电力负荷预测根据预测时间的长短分为短期、中期和长期,其中短期电力负荷预测是发电机组启停、调度和未来制定发电计划的重要依据,面对目前多元化的电力系统结构,传统的短期电力负荷预测难以达到预测精度,因此需要更准确的预测模型。目前,电力负荷预测有时间序列分析法和机器学习^[5]两种。时间序列分析法是按照时间顺序进行排列,形成统计的时间序列,运用数学方法进行预测,但这只限于线性的预测,一旦遇到非线性、波动性大的数据,其预测结果就会有极大的偏差。随着人工智能技术的蓬勃发展,机器学习是目前电力负荷预测的主流,支持向量机(support vector machine, SVM)^[6]、改进萤火虫算法^[7]、随机森林(random forest, RF)^[8]、卷积神经网络(convolution neural network, CNN)^[9]、长短期记忆神经网络(long short-term memory, LSTM)^[10-11]等人工智能预测模型备受大家青睐。但随着研究的深入,数据集越来越复杂,不同的数据集下各个算法的局限性也越来越明显,因此研究者提出多算法的融合以达到取长补短,获得更佳的预测效果^[12-13]。文献[12]基于经验模态分解(empirical mode decomposition, EMD)电力负荷数据进行短期负荷预测,该模型所用的经验模态分解所分解的低频分量容易出现模态混叠,不易表达出负荷波动的大趋势。文献[13]采用贝叶斯优化的卷积神经网络-双向门控循环网络(bidirectional gate recurrent unit, BiGRU)的混合神经网络,其模型对于数据的特征性会有一定的削弱。

影响短期电力负荷的因素主要有天气因素、日期因素、用户端等。随着新能源的不断发展,电力负荷预测面临更加复杂的状况^[14],电力负荷会更加趋向于非线性、随机性、波动性,通过变分模态分

解(variational mode decomposition, VMD)后的数据将大大弱化此性质。多特征负荷预测有明显的时间属性和天气属性,时间属性可以把时间按是否周末、本月第几天、本年第几天等做多特征处理;天气属性通过对温度、风向、风速等做多特征处理。为了充分挖掘电网中电力负荷背后的潜在信息并加以利用,文献[2]采用改进序列前向选择法(improved sequential forward selection, ISFS)通过迭代选取更好的特征,通过双层极端梯度提升(extreme gradient boosting, XGBoost)算法进行交叉预测,但是由于删除特征,从而减少非线性部分的预测精度。文献[3]提出一种注意力机制的多元负荷预测多任务学习模型(ResNet-LSTM-attention-multi-task learning, RLA-MTL),采用多特征负荷预测技术,在预测中能将多能负荷之间复杂耦合关系考虑进去,在一定程度上增强负荷预测的准确性。文献[4]使用双层XGBoost算法进行多特征预测,第一层进行特征处理,第二层进行预测,比单一的多特征预测精度更高,具有更优的泛化能力。

本文通过分解数据从而达到增加特征的目的得到第一层特征,其中某些特征过少导致的泛化问题能得到有效改善,采用LSTM与轻量级梯度提升机(light gradient boosting machine, LightGBM)算法堆叠^[15-16],利用两种算法的特点来分别对VMD分解量做特征处理,其中LightGBM能通过决策树深度避免采用众多杂糅的特征来进行预测时可能出现的过拟合问题,所以本模型既能考虑特征与负荷的时序相关性,也能获得特征与负荷的回归特性。经过算例分析,本文所提方法相较于传统VMD预测模型具有较高的预测精度。

1 基本原理

1.1 VMD分解原理

变分模态分解于2014年被提出,能有效地抑制EMD的模态混叠现象,与EMD的工作方式相异,分量的中心频率和带宽通过迭代搜索最优解的方式确定的^[17-18],将每个模态解调成平滑的基带,该方法对于采样和噪声方面具有更好的鲁棒性。

VMD是一种非平稳信号自适应分解方法,将原始的复信号分解为 K 个调幅和调频信号。信号被分解为 K 个本征模态分量(intrinsic mode portion,

IMP), 即 IMP 被重新定义为一个输入信号的模式函数 $u_k(t)$ 。

$$u_k(t) = A_k(t) \cos(\phi_k(t)), k = 1, 2, \dots, K \quad (1)$$

式中: $A_k(t)$ 为幅值且 $A_k(t) \geq 0$; $\phi_k(t)$ 为相位。

为了得到瞬时频率 $\omega_k(t)$, 用 $\phi_k(t)$ 对 t 求微分。

$$\omega_k(t) = \frac{d\phi_k(t)}{dt}, \omega_k(t) \geq 0 \quad (2)$$

具体的步骤如下。

1) 步骤 1, 对分解得到的每个模态函数做希尔伯特·黄变换(Hilbert-Huang transform, HHT)变换来计算其相关的解析信号及边际谱, 并通过中心频率 $e^{-j\omega_k t}$ 将模态函数 $u_k(t)$ 的频率变换到正确的基带中。

$$u_k(t) = \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \quad (3)$$

式中 $\delta(t)$ 为狄拉克分布; “*” 为卷积符号。

2) 步骤 2, 通过解调信号的高斯平滑度, 得到对带宽的估计, 从而构造出如下的约束变分问题。

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_{k=1}^K \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 \right\} \\ \text{s.t.} \sum_{k=1}^K u_k = f(t) \end{cases} \quad (4)$$

式中: $\{u_k\}$ 为信号分解出的 K 个模态分量集合 $\{u_1, u_2, \dots, u_K\}$; $\{\omega_k\}$ 为各模态对应的中心频率集合 $\{\omega_1, \omega_2, \dots, \omega_K\}$; $\|\cdot\|$ 为解调信号梯度的平方 L^2 范数; $f(t)$ 为序列。

3) 步骤 3, 引入二次惩罚项 α 和 Lagrange 乘数 $\lambda(t)$, 把问题转换成的无约束的变分问题。

$$\begin{aligned} L(\{u_k\}, \{\omega_k\}, \lambda) = & \alpha \sum_{k=1}^K \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 + \\ & \left\| \sum_k f(t) - \sum_k u_k(t) \right\|_2^2 + \left[\lambda(t), f(t) - \sum_{k=1}^K u_k(t) \right] \end{aligned} \quad (5)$$

交替方向乘子法解决问题, 进行不断优化更新 $u_k^{n+1}(\omega)$ 、 ω_k^{n+1} 、 $\lambda^{n+1}(\omega)$, 并在频域求得式(6)的鞍点。更新后公式为:

$$\hat{u}_k^{n+1}(\omega) = \frac{\hat{f}(\omega) - \sum_{i < k} \hat{u}_i^{n+1}(\omega) - \sum_{i > k} \hat{u}_i^n(\omega) + \frac{\hat{\lambda}^n(\omega)}{2}}{1 + 2\alpha(\omega - \omega_k^n)^2} \quad (6)$$

$$\hat{\omega}_k^{n+1} = \frac{\int_0^\infty \omega |\hat{u}_k^{n+1}(\omega)|^2 d\omega}{\int_0^\infty |\hat{u}_k^{n+1}(\omega)|^2 d\omega} \quad (7)$$

$$\hat{\lambda}^{n+1}(\omega) = \hat{\lambda}^n(\omega) + \tau(\hat{f}(\omega) - \sum_{k=1}^K \hat{u}_k^{n+1}(\omega)) \quad (8)$$

式中: n 为迭代次数; τ 为凸函数优化参数; 上标 $\wedge$ 表示该参数的估计值。

4) 步骤 4, 规定最大的迭代次数 N , 使得正数 n 满足 $n \leq N$, 存在任意 $\varepsilon > 0$, 满足式(9)。

$$\sum_k \|\hat{u}_k^{n+1}(\omega) - \hat{u}_k^n(\omega)\|_2^2 / \|\hat{u}_k^n(\omega)\|_2^2 \leq \varepsilon \quad (9)$$

满足式(9)时, 输出结果, 不满足则返回步骤 3。然后对式(6)求解得到的 K 个 IMP 的频域结果再进行反傅里叶变换, 得到其时域信号。

1.2 LSTM 网络

LSTM 是一种改进的时间循环神经网络(recurrent neural network, RNN), 在 RNN 的基础上增加了额外的遗忘门, 解决了训练模型时“梯度消失”的问题。其网络基本单元如图 1 所示^[19-20]。




图 1 LSTM 网络的基本单元

Fig. 1 Basic unit of LSTM network

LSTM 的基本单元包含了遗忘门、输入门和输出门。其中输入门和遗忘门对 LSTM 网络是否能记忆长期依赖有决定性作用^[21]。

遗忘门通过 Sigmoid 函数来参考前面的结果和目前内容来决定过去的状态信息是否丢弃。

$$f_t = \sigma(W_m[h_{t-1}, x_t] + b_m) \quad (10)$$

式中: x_t 为当前 t 时刻输入的信息; h_{t-1} 为上一次输出的结果; W_m 和 b_m 遗忘门权重矩阵和偏置项; σ 为 Sigmoid 函数; f_t 为遗忘门的状态, 其值愈接近于 0, 被遗忘的信息越多。

记忆单元中要保存多少信息由输入门决定。

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (11)$$

$$\tilde{M}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (12)$$

式中: W_i 、 W_c 为权重矩阵; b_i 、 b_c 为输入门偏置项; $\tanh$ 为激活函数; $\tilde{M}_t$ 为新记忆单元; i_t 为输入门的状态,其值越大,则新信息重要性越高,不重要的信息就会删除。

在进行输出之前,将确定更新的信息,即:

$$c_t = f_t \circ c_{t-1} + i_t \circ \tilde{c}_t \quad (13)$$

式中: c_t 为新的记忆单元; $\tilde{c}_t$ 为当前记忆单元; 符号“ $\circ$ ”为哈达玛乘。

在确定信息后,输出门将输出给外部状态。

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (14)$$

式中: W_o 为权重矩阵; b_o 为偏置项; o_t 为输出门的状态,值越接近于0,外部状态 h_t 就越能从记忆单元 c_t 中获取更多信息。

1.3 LightGBM

LightGBM是基于决策树算法的梯度提升框架,采用了两个新技术:梯度单边采样技术和独立特征合并技术,避免了低梯度长尾部分的影响,实现了特征捆绑,减少了特征数量。相比XGboost,训练时间仅为其1/10,且具有更高的准确度^[22-23]。为提取更多特征值,采用改进LightGBM,采用了二阶泰勒式和正则项,使模型有更高的信息增益。

LightGBM选择Leaf-wise策略,不断从每次分裂中选取最佳叶子,如图2所示,相比Level-wise有更准的精度。对于样本数量过少时出现的过拟合,可以通过调节参数max_depth来限制决策树的深度来避免。




图2 Leaf-wise生长策略

Fig. 2 Leaf-wise growth strategy

1.4 VMD-LSTM-LightGBM算法

通过VMD算法将负荷数据进行分解,分解出各个模态和残差量,再通过stacking堆叠的思想对VMD分解量进行预测,再将其预测结果作为特征进行LightGBM多特征预测。其模型如图3所示。

1)第一步:首先通过变分模态分解将原始负荷




图3 VMD-LSTM-LightGBM预测模型

Fig. 3 VMD-LSTM-LightGBM predictive model

数据进行分解,分解成 N 个模态和1个残差量。同时进行天气信息和日期信息的处理。

2)第二步:将 $N+1$ 个分解量进行预测,由于原始数据中的非线性信息被分解到残差量中,则对模态分量进行单特征预测会更加准确;残差量则需要多特征进行非线性学习、预测。为了避免梯度消失,本文采用LSTM进行预测。

3)第三步:对于常规的VMD预测模型,只需将模态分量和残差量的预测结果进行相加即可得到最终的预测负荷,本文模型将其作为特征量来进行多特征预测,同时加上日期信息和天气信息进行多特征负荷预测,选择能处理大量数据,能通过调整参数避免过拟合、能进行快速训练的LightGBM。

对于VMD-LSTM-LightGBM预测模型有以下创新。1)将传统的VMD预测模型做出改进,把模态分量与残差值分别做单特征与多特征预测,提升了VMD预测的精度。2)将VMD分解得到的模态分量和残差量作为特征进行预测,并通过实例验证,相比普通的VMD与机器学习预测模型的组合,效果有明显提升。

1.5 评价指标

本文选择平均绝对误差(mean absolute error, MAE) E_{MAE} 和平均绝对百分比误差(mean absolute percentage error, MAPE) E_{MAPE} 作为评价指标。 E_{MAE} 与 E_{MAPE} 越小,代表精度越准。具体的计算公式分别为式(15)——(16)。

$$E_{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{p}(i) - p(i)| \quad (15)$$

$$E_{\text{MAPE}} = \frac{1}{n} \sum_{i=1}^N \frac{|\hat{p}(i) - p(i)|}{p(i)} \times 100\% \quad (16)$$

式中： $p(i)$ 为电力负荷的实际值； $\hat{p}(i)$ 电力负荷的预测值； n 为预测验证数据数量； i 为预测点序列编号。 E_{MAE} 和 E_{MAPE} 均是值越小代表越接近真实数据。

2 数据准备

实验以国内某地区2018年1月1日—2021年8月31日的电力负荷和天气为数据样本，负荷数据采样周期为15 min，每天为96组数据，总共有128 544组数据，天气数据采样周期为1 d，总共有1 339组数据。将负荷数据前127 584组作为模型训练样本，将2021年8月22日—8月31日总共960组数据作为预测模型测试样本，并与实际负荷进行对比。

2.1 缺失值处理

通过拉格朗日插值法，对负荷数据中的388组空缺值做填补。

利用 $n+1$ 个离散点 $\{(x_i, y_i)\}_{i=0}^n$ ，通过插值函数即可得到插值多项式 $L_n(x)$ 。

$$L_n(x) = \sum_{i=0}^n l_i(x) y_i = \sum_{i=0}^n \frac{\omega_{n+1}(x)}{(x-x_i)\omega_{n+1}(x_i)} y_i \quad (17)$$

$$\omega_{n+1}(x) = (x-x_0)(x-x_1)\cdots(x-x_n) = (x_i-x_0)\cdots(x_i-x_{i-1})(x_i-x_{i+1})\cdots(x_i-x_n) \quad (18)$$

式中： $l_i(x)$ 为插值函数； $\omega_{n+1}(x)$ 为插值多项式。

利用已知的数求出拉格朗日差值多项式，再将待求节点代入该多项式，求出目标值。

2.2 特征处理

根据天气状况、最高温度、最低温度、白天风力风向、夜晚风力风向、日期共6个特征，通过分解特征，从数据中分解提取出“一年第几天”、“是否周末”、“一天第几小时”等11个特征(其中天气1、天气2，例如多云转小雨，多云为天气1，小雨为天气2)，将其转化成可识别的数字信号，整合成一个128 544×17的表格。根据皮尔逊相关度对全部特征量进行打分排序，权重和增益取值越高，特征量得分越高，则该特征变量对负荷影响越显著。各特征变量相关度排名如表1所示。

3 算例分析

3.1 算法设备条件

实验在Inter Core I7、内存为16G、512G固态硬盘硬件设备下完成，采用Windows平台的Python3.8

表 1 特征相关度排序

Tab. 1 Feature relevance ranking

排名	名称	得分	正/负相关
1	最低温度	0.423	正
2	最高温度	0.399	正
3	每天第几小时	0.190	正
4	季度	0.190	正
5	每年第几月	0.186	正
6	一年第几天	0.185	正
7	一年第几周	0.181	正
8	夜晚风力风向	0.148	负
9	天气1	0.145	正
10	白天风力风向	0.143	负
11	每小时第几分钟	0.100	负
12	是否周末	0.061	负
13	天气2	0.055	正
14	一周第几天	0.048	负
15	是否月初	0.039	负
16	每年第几天	0.035	正
17	是否季初	0.015	负

语言建立预测模型。

3.2 归一化

为了避免各特征值量纲不同，影响预测精度，同时加快梯度下降速度。因此，对负荷数据统一进行归一化处理：

$$Z' = \frac{Z - Z_{\min}}{Z_{\max} - Z_{\min}} \quad (19)$$

式中： Z' 归一化后的样本值； Z 为原样本值； $Z_{\max}$ 和 $Z_{\min}$ 为原样本集中的最大值和最小值。

3.3 VMD分解

电力负荷具有随机性和波动性，本文采用VMD对电力负荷数据进行分解，其中分解层数 K 的选择会影响VMD方法的分解效果，本文利用中心频率法确定分解层数 $K=4$ 。其余参数设置：起始中心频率 $\omega=0$ ，惩罚因子 $\alpha=2\ 000$ ；收敛判据 $r=10^{-7}$ 。VMD分解残差量如图4所示，分解得到模态分量如图5所示。

3.4 特征处理

残差量具有许多特征信息，从图4—5可以看出，分解出的残差量介于模态分量IMP3与IMP4之间。对于多特征负荷预测，优化数据非线性、随机性，残差量必不可少，能极大程度地提取负荷规




图 4 VMD 分解残差量

Fig. 4 VMD decomposition residual amount




图 5 VMD 分解模态分量

Fig. 5 Decomposition modal components of VMD

律, 代入多特征学习中能保证预测极值的准确率。从图 5 中可以看出, 分解后的数据更具有规律性, 更有利于模型对于负荷的学习和预测。

如表 2 所示, 在 4 个模态分量中, 均用单特征预测比多特征预测准确度更高, 因此 4 个模态分量选择采用单特征预测。

对于非线性明显的残差量, 则通过多特征预测时其精度更高。为了图片更清晰地展示其中区别, 均取前 50 个数据点进行预测对比如图 6、表 3 所示。加入残差量分量后, 与负荷特征相

表 2 模态分量评价指标对比

Tab. 2 Index comparison of modal component evaluation

模态分量	预测方法	$E_{MAPE}/\%$	E_{MAE}/kW
IMP1	单特征	0.001 37	317.825
	多特征	0.015	3 393.87
IMP2	单特征	0.027	113.77
	多特征	0.637	2 145.392
IMP3	单特征	0.275	128.139
	多特征	4.404	1 221.369
IMP4	单特征	1.115	132.228
	多特征	6.134	408.617




图 6 残差量预测对比图

Fig. 6 Residual prediction comparison chart

表 3 残差量评价指标对比

Tab. 3 Comparison of residual evaluation indicators

预测方法	$E_{MAPE}/\%$	E_{MAE}/kW
单特征	0.288	1 139.759
多特征	0.18	826.909

关度分析得分如表 4 所示。

表 4 VMD 分量相关度排序

Tab. 4 VMD component correlation

排名	名称	相关度
1	IMP1	0.891
2	IMP2	0.411
3	残差量	0.195
4	IMP3	0.152
5	IMP4	0.083

从表 4、图 5 可得出, IMP1 分解出电力负荷趋势, 其得分是最高的, 作为特征预测能提高负荷预测的非线性。

整合表 1 和表 4 的特征进行多特征负荷预测, 为更加直观地对比本文模型与目前负荷预测模型的差异, 设置两组对比模型, 对比模型包括:



用的负荷预测模型：LSTM、LightGBM；
加入 VMD 算法的预测模型：VMD-LSTM、
VMD-LightGBM。

各个模型均将预测结果进行反归一化求解，得到与真实负荷数据相同量纲的预测值。每个模型得到 960 组预测数据，为了使图片更清晰地展示各模型之间的区别，均取前 24 组数据，然后将预测值以及真实负荷值一同绘制于图 7 中。5 种算法的评价指标对比结果见表 5。




图 7 前 24 点模型预测结果

Fig. 7 First 24 points model prediction results

表 5 各模型评价指标对比

Tab. 5 Comparison of evaluation indicators of each model

预测模型	$E_{MAPE}/\%$	E_{MAE}/kW
LSTM	0.024 8	6 057.357
LightGBM	0.025 9	6 109.845
VMD-LSTM	0.005	1 165.763
VMD-LightGBM	0.015 9	3 697.955
VMD-LSTM-LightGBM	0.003 7	854.033

如表 5 所示，在预测精度方面，采用了 VMD 算法后，相较于单一的机器学习预测模型，MAPE 值降低了 1% 与 1.98%，当采用 VMD-LSTM-LightGBM 预测模型后，MAPE 值比 VMD-LSTM 与 VMD-LightGBM 分别下降了 0.13% 与 1.22%，可见本文预测模型结果更加准确，对特征的处理能进一步提升预测的精准度。

4 结论

本文针对多特征电力负荷预测精度不准，提出了一种 VMD-LSTM-LightGBM 多特征短期负荷预测模型，通过实例研究和消融研究，得出以下结论。

1) 本文采用 VMD 提取与电力负荷数据相关性最高的残差量，有效提高了多特征混合模型预测性能。通过改进 VMD 预测方式进行特征分析，提高了 VMD 各分解量的预测精度。将所预测的 VMD 分解量代入到特征进行 LightGBM 多特征负荷预测，通过与 VMD 加机器学习的组合预测方式进行对比，所提预测模型更能优化数据的非线性、非平稳、长记忆的问题，从而提升预测精度。

2) 本文在提高预测精度的同时，通过择优算法对 VMD 模态数量进行选择，避免主观性；针对综合能源负荷预测，加入更多特征，通过本文模型能做更多特征研究，并开展电、热、气的综合功率预测，充分发挥多特征和 VMD 分解的优势。

参考文献

- [1] 谭显东, 刘俊, 徐志成, 等. “双碳”目标下“十四五”电力供需形势[J]. 中国电力, 2021, 54(5): 1-6.
TAN Xiandong, LIU Jun, XU Zhicheng, et al. The “double carbon” target under the “14th Five-Year Plan” power supply and demand situation [J]. Electric Power, 2021, 54(5): 1-6.
- [2] TANG Y, LI Z, NI C, et al. Short-term load forecasting by multi-feature iterative learning based on ISFS and XGBoost [C]//2021 IEEE Sustainable Power and Energy Conference (iSPEC), December 22, 2021, Nanjing, China. New York: IEEE 2021: 3745-3752.
- [3] 王琛, 王颖, 郑涛, 等. 基于 ResNet-LSTM 网络和注意力机制的综合能源系统多元负荷预测[J]. 电工技术学报, 2022, 37(7): 1789-1799.
WANG Chen, WANG Yin, ZHENG Tao, et al. Multivariate load forecasting for integrated energy systems based on ResNet-LSTM networks and attention mechanisms [J]. Transaction of China Electrotechnical Society, 2022, 37(7): 1789-1799.
- [4] 孙超, 吕奇, 朱思瞳, 等. 基于双层 XGBoost 算法考虑多特征影响的超短期电力负荷预测[J]. 高电压技术, 2021, 47(8): 2885-2898.
SHUN Chao, LÜ Qi, ZHU Sitong, et al. Ultra-short-term power load forecasting based on a two-layer XGBoost algorithm considering the influence of multiple features [J]. High Voltage Engineering, 2021, 47(8): 2885-2898.
- [5] 赵洋, 王瀚墨, 康丽, 等. 基于时间卷积网络的短期电力负荷预测[J]. 电工技术学报, 2022, 37(5): 1242-1251.
ZHAO Yang, WANG Hanmo, KANG Li, et al. Short-term power load forecasting based on time-convolutional networks [J]. Transaction of China Electrotechnical Society, 2022, 37(5): 1242-1251.
- [6] 王小君, 毕圣, 徐云鹏, 等. 基于数据挖掘技术和支持向量机的短期负荷预测[J]. 电测与仪表, 2016, 53(10): 62-67.
WANG Xiaojun, BI Sheng, XU Yunkun, et al. Short-term load forecasting based on data mining techniques and support vector machines [J]. Electrical Measurement and Instrumentation, 2016, 53(10): 62-67.
- [7] ABDOLLAH KAVOUSI-FARD A, HAIDAR SAMET B, FATEMEH MARZBANI C. A new hybrid modified firefly

- algorithm and support vector regression model for accurate short term load forecasting-sciencedirect [J]. Expert Systems with Applications, 2014, 41(13): 6047 – 6056.
- [8] 李焱,贾雅君,李磊,等.基于随机森林算法的短期电力负荷预测[J].电力系统保护与控制,2020,48(21):117 – 124.
LI Yan, JIA Yajun, LI Lei, et al. Short-term power load forecasting based on random forest algorithm [J]. Power System Protection and Control, 2020, 48(21): 117–124.
- [9] 赵兵,王增平,纪维佳,等.基于注意力机制的CNN-GRU短期电力负荷预测方法[J].电网技术,2019,43(12):4370 – 4376.
ZHAO Bing, WANG Zengping, JI Weijia, et al. CNN-GRU short-term power load forecasting method based on attention mechanism [J]. Power System Technology, 2019, 43 (12) : 4370 – 4376.
- [10] 孙庆凯,王小君,张义志,等.基于LSTM和多任务学习的综合能源系统多元负荷预测[J].电力系统自动化,2021,45(5): 63 – 70.
SUN Qingkai, WANG Xiaojun, ZHANG Yizhi, et al. Multivariate load forecasting for integrated energy systems based on LSTM and multi-task learning [J]. Automation of Electric Power Systems, 2021, 45(5): 63 – 70.
- [11] 庞传军,张波,余建明.基于LSTM循环神经网络的短期电力负荷预测[J].电力工程技术,2021,40(1):175 – 180,194.
PANG Chuanjun, ZHANG Bo, YU Jianming. Short-term power load forecasting based on LSTM recurrent neural network[J]. Electric Power Engineering Technology, 2021, 40(1) : 175 – 180,194.
- [12] 徐岩,向益锋,马天祥.基于EMD-CNN-LSTM混合模型的短期电力负荷预测[J].华北电力大学学报(自然科学版),2022, 49(2):81 – 89.
XU Yan, XIANG Yifeng, MA Tianxiang. Short-term power load forecasting based on EMD-CNN-LSTM hybrid model[J]. Journal of North China Electric Power University (Natural Science Edition), 2022, 49(2): 91 – 89.
- [13] 邹智,吴铁洲,张晓星,等.基于贝叶斯优化CNN-BiGRU混合神经网络的短期负荷预测[J].高电压技术,2022,48(10): 3935 – 3945.
ZOU Zhi, WU Tiezhou, ZHANG Xiaoxing, et al. Short-term load prediction based on Bayesian optimized CNN-BiGRU hybrid neural network [J]. High Voltage Engineering, 2022, 48(10): 3935 – 3945.
- [14] 崔树银,汪昕杰.基于最大信息系数和多目标Stacking集成学习的综合能源系统多元负荷预测[J].电力自动化设备,2022, 42(5):32 – 39,81.
CUI Shuyin, WANG Xinjie. Multivariate load forecasting for integrated energy systems based on maximum information coefficients and multi-objective Stacking integrated learning [J]. Electric Power Automation Equipment, 2022, 42(5): 32 – 39, 81.
- [15] 史佳琪,张建华.基于多模型融合Stacking集成学习方式的负荷预测方法[J].中国电机工程学报,2019,39(14):4032 – 4042.
SHI Jiaqi, ZHANG Jianhua. Load forecasting method based on multi-model fusion Stacking integrated learning approach [J]. Proceedings of the CSEE, 2019, 39(14): 4032 – 4042.
- [16] QIAN Z, JW A, YUAN M A, et al. Short-term load forecasting method with variational mode decomposition and stacking model fusion [J]. Sustainable Energy Grids and Networks, 2022, 30(9): 2352 – 4677.
- [17] 张淑清,宿新爽,陈荣飞,等.基于变分模态分解和FABP的短期电力负荷预测[J].仪器仪表学报,2018,39(4):67 – 73.
ZHANG Shuqing, SHU Xinshuang, CHEN Rongfei, et al. Short-term power load forecasting based on variational modal decomposition and FABP [J]. Chinese Journal of Scientific Instrument, 2018, 39(4): 67 – 73.
- [18] 李浩,张禄亮.基于改进VMD和特征分布系数的配电网高阻抗接地故障检测方法[J].南方电网技术,2022,16(12):109 – 117.
LI Hao, ZHANG Luliang. High impedance grounding fault detection method for distribution network based on improved VMD and characteristic distribution coefficient [J]. Southern Power System Technology, 2022, 16(12): 109 – 117.
- [19] BENGIO Y. Learning long-term dependencies with gradient descent is difficult[J]. IEEE Transactions on Neural Networks, 2002, 5(2):157 – 166.
- [20] YU Y, SI X, HU C, et al. A review of recurrent neural networks: LSTM cells and network architectures [J]. Neural Computation, 2019, 31(7): 1235 – 1270.
- [21] 郭建鑫,赵玉顺,王志宇,等.基于LMD和LSTM的盆式绝缘子典型缺陷局部放电模式识别方法[J].南方电网技术,2021, 15(8):95 – 105.
GUO Jianxin, ZHAO Yushun, WANG Zhiyu, et al. Partial discharge pattern recognition method of typical defects in basin insulator based on LMD and LSTM [J]. Southern Power System Technology, 2021, 15(8): 109 – 117.
- [22] 陈伟楠,胡志坚,岳菁鹏,等.基于长短期记忆网络和LightGBM组合模型的短期负荷预测[J].电力系统自动化, 2021,45(4):91 – 97.
CHEN Weinan, HU Zhijian, YUE Jingpeng, et al. Short-term load forecasting based on a combined long and short-term memory network and LightGBM model [J]. Automation of Electric Power Systems, 2021, 45(4): 91 – 97.
- [23] 张爱枫,段新宇,何泉峰.基于CNN和LightGBM的新型风电功率预测模型[J].电测与仪表,2021,58(11):121 – 127.
ZHANG Aifeng, DUAN Xinyu, HE Xiaofeng. A novel wind power prediction model based on CNN and LightGBM [J]. Electrical Measurement and Instrumentation, 2021, 58(11): 121 – 127.

收稿日期: 2022-11-07

作者简介:

张未(1997),男,硕士研究生,研究方向为电力系统负荷预测, zhangwei@stu.cqut.edu.cn;

余成波(1965),男,通信作者,教授,博士,研究方向为信息获取与处理技术、远程测试与控制技术(无线传感网络)及电气设备物联网技术, yuchengbo@cqut.edu.cn;

王士彬(1980),男,高级工程师,博士,从事电力建设及设备安装维护管理工作, greatceo@sina.com。